

SVEUČILIŠTE U ZAGREBU
FAKULTET ELEKTROTEHNIKE I RAČUNARSTVA

SEMINAR

Data mining u sportu

Alen Murtić

Voditelj: *doc. dr. sc. Damir Pintar*

Zagreb, travanj, 2017.

Sadržaj

1. Uvod	1
2. Potreba i korist data mininga u sportu	2
2.1. Izvorišne ideje	2
2.2. Potreba za deskriptivnom analizom	3
2.2.1. Raspodjela resursa	3
2.2.2. Analiza kvalitete i stila vlastite momčadi	4
2.2.3. Optimiranje strategije	4
2.2.4. Analiza protivnika	4
2.2.5. Procjena slučajnosti	4
2.3. Potrebe za prediktivnom analizom	4
2.3.1. Predviđanje rezultata utakmica	5
2.3.2. Kvaliteta igrača kroz godine te rizik ozljeda	5
2.3.3. Simulacija taktike	5
3. Postojeća rješenja	6
3.1. Košarka	6
3.2. Nogomet	6
3.3. Američki nogomet	6
4. Nove mogućnosti	8
5. Zaključak	9
6. Literatura	10
7. Sažetak	11

1. Uvod

Proteklih 120 godina sport je polako postajao sve važniji element u svakodnevnom životu "običnih" ljudi. Iz krpenih lopti i dresova razvila se milijunska industrija koja pazi na svaki detalj kako bi sportaši postigli najveće moguće rezultate. Jedan od najvažnijih aspekata momčadskih sportova je donošenje odluka - treneri, sportski direktori, vlasnici i ostali djelatnici upravljaju velikim rizicima, a često nemaju potpune ili kvalitetne informacije. Što je pomalo otužna činjenica u trenutnom informacijskom vremenu kada postoji toliko dostupnih podataka o sportu. Zato je stvorena posebna disciplina analize podataka u cilju poboljšanja kvalitete odluka koje sportski djelatnici moraju donositi.

Posebni dio ekosustava modernog sporta je klađenje. Sportsko klađenje mnogima je jedini razlog zašto prate sport. Kladionice također zarađuju milijune te su često veliki sponzori sportkih momčadi, npr. glavni sponzor 10 od 20 trenutnih članova engleske Premier lige su tvrtke koje nude igre na sreću. Svaki sportski fan koji se razumije u matematiku jednom je želio napraviti model predviđanja utakmica, no kladionice ne dopuštaju najuspješnijim igračima da se klade nakon određenog dobitka. Kladionice su uvijek na dobitku, a to postižu pažljivim promjenama koeficijenata uz pomoć naprednih algoritama. Očito je one imaju veliku potrebu za analizom podataka kod promjene koeficijenata, detekcije najboljih igrača te detekcije namještenih sportskih dvoboja.

Data mining (rudarenje podataka) je vrsta analize podataka čiji je cilj pronalaženje relevantnih informacija u podacima te iskorištenje istih za poboljšanje procesa donošenja odluka. Postoje dvije kategorije *data mininga*: deskriptivna (otkrivajuća, opisna) te prediktivna (predviđajuća) analiza. Deskriptivna analiza u nestrukturiranim, prevelikim ili nejasnim podacima nalazi "skrivena" informacije te ih kranjem korisniku predstavlja u razumljivom obliku. Prediktivna pokušava naći pravilnosti u podacima te ih iskoristiti za predviđanje budućih. Ne postoji neka čvrsta granica između *data mininga* i ostalih vrsta analiza podataka, no njegova najčvršća značajka je traženje i dubinska analiza.

Ovaj seminarski rad opisuje potrebu i korist *data mininga* u sportu, postojeća rješenja te moguće nadogradnje. Fokusiran je na 3 vrlo različita timska sporta: košarku, nogomet i američki nogomet kako bi čitatelju prikazao što širi opus problema i ideja *data mininga* u sportu.

2. Potreba i korist data mininga u sportu

Ovo poglavlje bavi se razlozima korištenja *data mininga* u sportu prolazeći kroz 3 točke: izvorišne ideje te potrebe za deskriptivnom odnosno prediktivnom analizom. Važno je naglasiti da niti jedan sustav nije napravljen isključivo s ciljem zadovoljavanja neke od točaka, već je ovo jedan pokušaj klasifikacije područja kojima se *data mining* u sportu bavi.

2.1. Izvorišne ideje

Većina ideja statističke analize u sportu dolazi iz baseballa, a za to postoje jasni razlozi:

1. baseball je sport s dugom tradicijom i velikom popularnošću, uvijek je bio profitabilan pa je privlačio mnogo novih ideja i pametnih ljudi. Bitna je i činjenica da je američka profesionalna liga MLB nastala spajanjem dvaju liga AL (American league) i NL (National league) koji su unutar MLB-a i dan danas donekle neovisni. Zbog toga su postojala dva "tržišta" za promociju sportske statistike.
2. legende sporta vrlo su važan element razgovora o baseballu, a budući da on ima turbulentnu i rasističku prošlost u SAD-u, postoji potreba za revizijom nekih dijelova iste.
3. njime dominira statistika, pogledom na detaljne rezultate od prije 100-injak godina može se razumjeti mnogo više o utakmicama nego kod ikojeg drugog sporta.

U engleskom jeziku postoji izraz *sabermetrics* koji označava korištenje statistike u cilju razumijevanja baseballa (danas se koristi i u kontekstu ostalih sportova), a potječe od organizacije SABR (Society for American Baseball Research) nastale 1971. s ciljem elemenata tog sporta. Specifičnost organizacije je u tome da je sačinjena od novinara, bivših igrača, navijača, statističara i ostalih dionika sporta kako bi pružila što širi i točniji pogled na teme koje ju zanimaju.

Pravi rast data mininga u baseballu počinje kasnih 1990-ih i ranih 2000-ih, a najviše ga simboliziraju dvojica menadžera Billy Beane i Theo Epstein. Billy Beane je 1998. postao generalni menadžer (GM) Oakland Athleticsa, momčadi s prilično ograničenim budžetom u odnosu na protivnike. Beane je osmislio princip nazvan Moneyball, ideju kupovine podcijenjenih igrača u cilju optimizacije potrošnje novca. Igrače je evaluirao analitičkim metodama zasnovanim na matematici. Beane je godinama imao značajno bolje rezultate od mnogih skupljih momčadi, ali Oakland nije uspio osvojiti ligu. Theo Epstein je 2002. sa samo 28 godina postao GM Boston Red Soxa, kluba koje je 84 bio bez trofeja prvaka. Samo 2 godine kasnije uspjeli su osvojiti naslov te to ponoviti 2007.

Dominacija statistike u baseballu pomiješana s američkom zabranom tradicionalnog klađenja dovela je do značajnog razvoja amaterskog data mininga za *fantasy baseball* (natjecanja u kojima sudionici biraju igrače, a birana moćad s najboljom ukupnom statistikom pobjeđuje, a njezin autor dobiva nagradu). Vrhunski igrači često postaju zaposlenici profesionalnih klubova. Takva intelektualna širina zaslužna je za konstantan napredak *data mininga* u baseballu.

Najveća godišnja konferencija sportske analitike je Sloan Sports Analytics Conference koja se svake godine održava na prestižnom sveučilištu MIT. [9]

2.2. Potreba za deskriptivnom analizom

Potreba za deskriptivnom analizom na bazičnoj razini prilično je očita - što više točnih informacija uvijek je bolje nego manje. No, budući da se ne možemo baviti svime, potrebno je identificirati ključne podatke koje želimo saznati.

2.2.1. Raspodjela resursa

Neizbježna činjenica svakodnevnog života ili upravljanja bilo kojom vrstom organizacije je ograničenost resursa, stoga ona očito vrijedi i za sportske klubove. Resurse koje klubovi imaju možemo podijeliti u 2 skupine: sportski i financijski.

Kao financijski resurs razmatramo novac koji može biti siguran ili potencijalan, baš kao kod svakog poduzeća, no specifičnost sporta u odnosu na većinu drugih djelatnosti da postoji i potpuno siguran budući novac (npr. minimalne naknade za TV prava na kraju sezone). Raspodjela financijskih resursa u sportu bavi se vjerojatnošću postizanja određenih sportskih i/li financijskih (npr. dividende vlasnicima, vraćanje kredita za stadion) ciljeva uz investiciju financijskih u sportske resurse. Standardno pitanje ovog područja je "Isplati li se potrošiti iznos x na odštetu/plaću igrača y ?".

Sportski resursi vrlo su različiti od sporta do sporta, pa i između različitih liga istog sporta te navodim najčešće: dostupna minutaža, vrijeme treniranja, zdravlje igrača, dozvoljeni negativni rezultati do ostvarenja cilja, izbori na *draftu* i sl. Oni mogu biti jednaki za sve momčadi (npr. dostupna minutaža), no kao što se vidi u popisu, uglavnom nisu, stoga je njihova analiza još izazovnija i zanimljivija. Dobar dio sportskih resursa nužno je opisivati i prediktivno kako bi saznali kvalitetnije informacije u cilju donošenja odluka.

2.2.2. Analiza kvalitete i stila vlastite momčadi

Izvorišna ideja deskriptivne analize je razumijevanje prednosti i mana vlastite momčadi kako bi treneri i/li sportski direktori imali točne informacije. Prvenstveno tražimo opis igrača u različitim ulogama kako bi otkrili alternativne strategije igranja ili kupovine novih igrača. Analiza kvalitete bavi se pretvorbom konkretnih podataka iz utakmica ili treninga u što jasniji opis, tj. pronalaženjem podataka koji ne bi bili uočeni.

2.2.3. Optimiranje strategije

Optimiranje strategije izravno je poduprto znanjem dobivenim iz prethodne dvije točke. Umjesto da ovisimo o kreativnosti ljudi, optimiranje strategije nalazi daje ocjenu različitih strateških opcija te sugerira one koje sustav vidi kao najbolje.

2.2.4. Analiza protivnika

Kvalitetna analiza protivnika dug je i naporan proces koji bi trebalo pojednostaviti što je više moguće. Ona zapravo radi na sličan način kao optimiranje strategije, samo što traži najčešće protivnikove ideje i mane te njegov stil protiv momčadi kao naše. Nalazi se na granici opisa i predviđanja.

2.2.5. Procjena slučajnosti

Donošenje odluka u svakom sportu, a posebno nogometu, je često temeljeno na pitanju: učiniti promjenu ili ne? Treba li klub dati otkaz treneru, treba li trener zamijeniti napadača koji ne postiže golove nekoliko utakmica, promijeniti taktiku ili ne i sl.? Analitički pristup može dati odgovor koja je vjerojatnost da se dogodio negativan ishod utakmice uz igru koju je momčad pružila. Nekad je lako shvatiti da je protivnički vratar imao odličan dan i da je zato naš tim izgubio, ali u pravilu je teško objektivno procijeniti je li nešto slučajnost ili realnost, pogotovo ako se klub nalazi u zoni ispadanja. Npr. u sezoni 2011.-12. Wigan FC je imao katastrofalne rezultate prvih 29 kola engleske Premier lige, iako su očito igrali kvalitetno. No, klub nije dao otkaz treneru i sezonu je završio s 9 pobjeda iz 11 utakmica i spasio se od ispadanja. Takva strpljivost je rijetka, a dubinska analiza rezultata može dati odgovor isplati li se čekati.

2.3. Potrebe za prediktivnom analizom

Osnovna potreba za prediktivnom analizom je činjenica da se u sportu uspjeh uglavnom ne procjenjuje trenutnim stanjem, nego rezultatima u nekoj budućnosti do

koje tek treba doći. Zato je vrlo bitno imati predstavku kako će neki igrači doprinosti momčadi u budućnosti.

S druge strane - kladionice imaju konstantnu potrebu što točnijeg predviđanja rezultata utakmice i ostalih statistika. One su tvrtke koje vrijede milijune i rade s ukupnim milijunskim iznosima kod najatraktivnijih utakmica te im svaka mala optimizacija koeficijenata može donijeti ogromne iznose dodatnog novca.

2.3.1. Predviđanje rezultata utakmica

Predviđanje rezultata utakmica idejno je osnovni, a izvedbeno najteži dio prediktivne analize. Ti podaci bitni su i kladionicama, kako bi povećale zaradu, i klubovima, za što informiranije planiranje sezone. Razvijene su različite tehnike predviđanja rezultata, od standardnih 3-klasnih klasifikatora (pobjeda, poraz, neriješeno) do vremenski-ovisnih Markovljevih lanaca, posebno popularnih u nogometu.

2.3.2. Kvaliteta igrača kroz godine te rizik ozljeda

Klubovima najzanimljiviji aspekt prediktivne analize je predviđanje kvalitete igrača kroz godine. Kad bi savršeno znali kako će se igrač razvijati, ne bi bacali novce na skupe i beskorisne transfere. Tu se u obzir uzima i rizik ozljeda određenog igrača, mnogi veliki talenti propadnu zbog nesretnih zdravstvenih okolnosti. Ideja se provodi u stvarnost nekom vrstom regresije krivulje kvalitete s obizrom na bazu podataka iz prošlosti te sličnosti igrača s drugima (visina, težina, prethodne ozljede, brzina, stil igre, dosadašnja krivulja, itd.).

2.3.3. Simulacija taktike

Simulacija taktike zanimljiva je ideja rješavanja donošenja odluka unutar utakmica, ona se oslanja na analizu protivnika, no njezina je bit predvidjeti kako bi protivnik reagirao kod određenog rezultata, koju će momčad izabrati i slično. Simulacija taktike izuzetno je bitna u nogometu zbog postojanja samo 3 zamjene, momčad koju trener odabere bi mogla biti što raznovrsnija kako bi odgovorila na različite mogućnosti protivnika, a onda kasnije uvoditi specijalizirane zamjene kod neke od situacija.

3. Postojeća rješenja

3.1. Košarka

3.2. Nogomet

3.3. Američki nogomet

Američki nogomet specifičan je spor zbog toga što se igra prekida nakon svake akcije te postoji mogućnost zamjene igrača nakon istih. Na terenu svaka momčad ima jedanaestoricu od kojih samo jedan ili dvoje igraju loptom u pojedinoj napadačkoj akciji (osim kod jako, jako rijetkih dodavanja unazad) zato što je dozvoljeno samo 1 dodavanje prema naprijed, no svi ostali trče ili blokiraju kako se otvorilo što više prostora za igrača s loptom. Sve akcije su tajne unutar momčadi te stoga ne postoji mnogo javnih modela za američki nogomet. Ono što znamo je da neki klubovi koriste *data mining* jer se u zadnje vrijeme ruši mnogo starih neefikasnih principa (držanja osrednjih veterana, visokih odabira trkača na *draftu*, favoriziranje trčanja u odnosu na dodavanje) te dodaju neki novi (kasnije navedeni).

Iako je većina *data mininga* u NFL-u tajna, jedna od najnaprednijih sportskih *data mining* stranica je specijalizirana za američki nogomet, Pro Football Focus. Također postoje doslovno stotine stranica koje se bave fantasy footballom, dozvoljenim oblikom kladenja u Americi.

Opišimo kako je svaki od starih principa unaprijeđen te koji su novi principi:

- Držanje osrednjih veterana [5]

Budući da u NFL-u postoji maksimalni iznos novaca koje momčadi smiju potrošiti, da bi vrhunski klubovi ostajali pri vrhu, moraju povremeno puštati osrednje starije igrače da odu te plaćati samo najbolje. Specifičnost lige je da u slučaju odlaska najboljih igrača klubovi dobiju kompenzacijske odabire na *draftu*. Dok tog ograničenja nije bilo (prije 1990.-te), klubovi su zadržavali sve korisne igrače. No, sada ne mogu, te moraju postati praktički tvornice igrača kako bi ostali u vrhu.

- Visoki odabir trkača na *draftu* [6]

Budući da je liga počela favorizirati dodavanja te da je skauting bolji nego ikada, u NFL-u se više ne isplati odabirati trkače visoko zato što ih se lako može naći vrlo jeftino, isključujući vrhunske talente. Trkači imaju kraće karijere nego druge napadačke pozicije zbog izloženosti ozljedama te je stoga i vremenska vrijednost takvog odabira mala. [8]

- Favoriziranje trčanja u odnosu na dodavanje

Zbog novih pravila koja zaštićuju zdravlje igrača, NFL momčadima je sve lakše izvoditi uspješna dodavanja koja su gotovo uvijek dalja nego uspješne trke te se stoga očito osjeti velika promjena u stilu igre. [6]

Osim razbijanja starih principa, formirani su i neki novi od kojih spomenimo dva najbitnija:

- Shvaćanje vrijednosti napadačka linije
Napadačka linija je 5 igrača u sredini svake napadačke akcije koji ne smiju napredovati s loptom u rukama (niti je hvatati) te su zato dugo vremena bili potcijenjeni. Njihov zadatak je čuvanje dodavača ili trkača od protivničke obrane. Međutim, budući da je dodavač najbitniji i najplaćeniji igrač svakog kluba, logično je da ga se mora što bolje zaštititi, pa makar i pod cijenu slabljenja drugih dijelova momčadi. Empirijski je dokazano da klubovi koji više resursa utroše u ofenzivnu liniju imaju bolje rezultate dodavanja. [1]
- Izbacivanje srednje dugih dodavanja [4]
Nešto potpuno novo u NFL-u, idejno preuzeto iz košarke (pucanje mnogo trica), je izbacivanje srednje dugih dodavanja u korist dugačkih. Statistika pokazuje da su srednje duga dodavanja slično uspješna/neuspješna, a duga daju veću korist. Duga dodavanja imaju veću varijancu te se tako mogu nadoknaditi veliki zaostaci, baš kao New England Patriotsi u Super Bowlu ove godine. [2]

4. Nove mogućnosti

5. Zaključak

6. Literatura

- [1] Dave Archibald. Offensive line investment: They pay these guys how much?!, 2015.
- [2] Phillip Barnett. Aesthetic: The deep ball, 2017.
- [3] Luke Benstead. *Beginning OpenGL Game Programming, 2nd Edition*. Delmar Learning, 2nd edition, June 2010.
- [4] Brian Burke. Deep vs. short passes, 2010.
- [5] Kevin Clark. The nfl has an age problem – the ringer, 2016.
- [6] Rich Exner and The Plain Dealer Bill Lubinger. Is there no place for the running back high in the nfl draft? analysis, 2012.
- [7] Dave Shreiner and The Khronos OpenGL ARB Working Group. *OpenGL Programming Guide: The Official Guide to Learning OpenGL, Versions 3.0 and 3.1 (7th Edition)*. Addison-Wesley Professional, 7 edition, July 2009.
- [8] Chase Stuart. Declining running back value in the draft, 2014.
- [9] web. Mit sloan sports analytics conference, 2017.

7. Sažetak